



Travail réalisé par :

Adem Jlassi
Jasser houimli

WORLD HAPPINESS REPORT (2015–2019)

Analyse statistique des déterminants du bonheur à travers les pays

PROJET ACADÉMIQUE

TECHNIQUES UTILISÉES

- Analyse univariée (moyenne, médiane, écart-type, histogrammes, boîtes à moustaches)
- Analyse bivariée (corrélations, nuages de points, ANOVA, test du Khi-deux)
- Analyse multivariée (régression linéaire multiple, diagnostics de régression)
 - Analyse en composantes principales (ACP)
 - Clustering K-means

JEU DE DONNÉES : World Happiness Report (2015–2019)

- 5 années de données
 - Environ 156 pays
 - 781 observations
- 10 variables principales

OBJECTIF : Analyser les principaux facteurs économiques, sociaux et sanitaires qui influencent le bonheur des pays et étudier leur évolution au fil du temps.

ANNÉE ACADÉMIQUE : 2025/2026

WORLD HAPPINESS REPORT DATASET (2015–2019)

Description of the Dataset



OVERVIEW

The dataset contains annual data from the World Happiness Report for the years 2015 to 2019. It includes information on happiness scores and key explanatory factors for countries around the world.



DATASET STRUCTURE

- 5 years of data: 2015, 2016, 2017, 2018, 2019
- 781 total observations
- 156 countries (approximately)
- 10 main variables



VARIABLES

- **Country:** Name of the country
- **Region:** Region or continent
- **Year:** Observation year (2015–2019)
- **Happiness:** Happiness Score (dependent variable)
- **GDP:** Economy (GDP per Capita)
- **Family:** Social support
- **Health:** Healthy life expectancy
- **Freedom:** Freedom to make life choices
- **Generosity:** Generosity
- **Corruption:** Perceptions of corruption



DATA SOURCE

World Happiness Report published by the Sustainable Development Solutions Network (SDSN).



DATA TYPES

- **Quantitative:** Happiness, GDP, Family, Health, Freedom, Generosity, Corruption
- **Qualitative:** Country, Region, Year (treated as categorical for analysis)

EXAMPLE OF THE DATASET

Country	Region	Year	Happiness	GDP	Family	Health	Freedom	Generosity	Corruption
Switzerland	Western Europe	2015	7.587	1.39651	1.34951	0.94143	0.66557	0.29678	0.41978
Iceland	Western Europe	2015	7.561	1.30232	1.40223	0.94784	0.62877	0.43630	0.14145
Denmark	Western Europe	2015	7.527	1.32548	1.36058	0.87464	0.64938	0.34139	0.48357
Norway	Western Europe	2015	7.522	1.45900	1.33095	0.88521	0.66973	0.34699	0.36503
Canada	North America	2015	7.427	1.32629	1.32261	0.90563	0.63297	0.45811	0.32957
...	...	...	...	...	...	...	...	...	...



SIZE

781 observations
10 variables



PURPOSE

To analyze the factors that influence happiness across countries and over time.



ANALYSES PERFORMED

Descriptive statistics, correlation analysis, ANOVA, chi-square test, multiple linear regression, PCA, and clustering.



KEY INSIGHT

The dataset helps understand how economic, social, and health factors relate to the happiness of nations.

Objectifs du projet

Ce rapport présente une analyse statistique complète du World Happiness Report. Les scores de bonheur de 170 pays sur 5 ans sont étudiés à travers trois niveaux : (1) Univarié – distribution et statistiques descriptives ; (2) Bivarié – corrélations, comparaisons de groupes (ANOVA, chi-deux) ; (3) Multivarié – régression multiple, ACP, clustering K-means.

Table des Matières

1	Préparation et Description des Données	§1
2	Analyse Univariée	§2
3	Analyse Bivariée	§3
4	Analyse Multivariée – Régression Multiple	§4
5	Analyse en Composantes Principales (ACP)	§5
6	Classification K-means	§6
7	Conclusion	§7

1. Préparation et Description des Données

1.1 Collecte et nettoyage

Les fichiers CSV des années 2015 à 2019 ont été chargés séparément, car chaque année présente des noms de colonnes différents. Une fonction de standardisation a été appliquée pour homogénéiser les variables clés. Les régions manquantes (2017–2019) ont été imputées via le package `countrycode`. Après suppression des lignes incomplètes (`na.omit`), le jeu de données final comprend **781 observations** couvrant **170 pays**.

1.2 Structure du jeu de données final

Nombre d'observations	781
Nombre de pays distincts	170
Période couverte	2015 – 2019 (5 années)
Variables retenues	10 (Year, Country, Region + 7 indicateurs numériques)
Valeurs manquantes	0 (supprimées par <code>na.omit</code>)

1.3 Description des variables

VARIABLE CIBLE

😊 **Happiness**

Score de bonheur (0–10)

[Continue](#)

NIVEAU DE VIE ÉCONOMIQUE

💰 **GDP**

PIB par habitant (log)

[Continue](#)

LIENS SOCIAUX

👨👩👦 **Family**

Soutien social perçu

[Continue](#)

SANTÉ PUBLIQUE

🏥 **Health**

Espérance de vie en bonne santé

[Continue](#)

LIBERTÉ INDIVIDUELLE

🗳️ **Freedom**

Liberté de faire des choix

[Continue](#)

DIMENSION ALTRUISTE

💖 **Generosity**

Générosité (dons charitables)

[Continue](#)

GOUVERNANCE

🗳️ **Corruption**

Confiance dans les institutions

[Continue](#)

16 MODALITÉS

🌐 **Region**

Région du monde

[Catégorielle](#)

2015 À 2019

📅 **Year**


Année d'enquête

[Facteur](#)

2. Analyse Univariée

2.1 Statistiques descriptives

Représentation des intervalles [Min → Max] avec la médiane (trait noir) et la moyenne (•) pour chaque variable.




Barres d'étendue : Q1–Q3 coloré · trait = médiane · point = moyenne · extrêmes en transparence

Le score de bonheur mondial moyen est de **5.38/10**, avec une médiane légèrement inférieure (5.32), indiquant une légère asymétrie positive. L'écart entre le minimum (2.69 – Afghanistan) et le maximum (7.77 – Finlande) reflète d'importantes inégalités mondiales de bien-être. GDP, Health et Corruption présentent de fortes asymétries à droite (skewness positif), typiques des indicateurs économiques et institutionnels.

2.2 Distribution du score de bonheur

Distribution du Score de Bonheur (2015–2019)

La distribution est approximativement symétrique, centrée sur 5.38



Source : World Happiness Report

Figure 1a – Histogramme du score de bonheur (2015–2019). La ligne pointillée rouge indique la moyenne (5.38).

2.3 Évolution temporelle du bonheur (2015–2019)





Figure 1b – Boxplots du score de bonheur par année. On observe un pic en 2016 suivi d'un léger déclin jusqu'en 2019.

L'année 2016 affiche la distribution la plus haute (cohérent avec $\beta_{\text{Year2016}} = +0.317$ en régression). Le déclin progressif de 2017 à 2019 (-0.24 à -0.28) peut être lié à des tensions géopolitiques et économiques mondiales (Brexit, instabilité politique, ralentissement économique).

2.4 Répartition par niveau de bonheur



3. Analyse Bivariée

3.1 Matrice de corrélation de Pearson

Tous les coefficients sont significatifs ($p < 0.001$). Le graphique ci-dessous montre la force de corrélation avec le bonheur pour chaque prédicteur.




Figure 2 – Corrélations de Pearson avec Happiness. Tous les coefficients $p < 0.001$.

Le PIB ($r=0.79$) est le prédicteur le plus fortement corrélé au bonheur, devant la santé ($r=0.74$) et le soutien social ($r=0.65$). Ces trois variables forment le 'noyau dur' du bien-être. La générosité ($r=0.14$) présente la corrélation la plus faible mais reste significative.

Matrice de Corrélation – World Happiness




Figure 2 – Heatmap de corrélation. Les cases bleues indiquent des corrélations positives, rouges des négatives.
GDP-Health ($r=0.79$) révèle une colinéarité à surveiller.

Le PIB ($r=0.79$) est le prédicteur le plus fortement corrélé au bonheur, devant la santé ($r=0.74$) et le soutien social ($r=0.65$). Ces trois variables forment le 'noyau dur' du bien-être. La générosité ($r=0.14$) présente la corrélation la plus faible mais reste significative.

3.2 Nuages de points bivariés




Figure 3a – PIB vs Bonheur ($r=0.79$). Relation quasi-linéaire robuste. Les pays d'Europe de l'Ouest (vert) dominent le quadrant supérieur droit.





Figure 3b – Liberté de choix vs Bonheur ($r=0.55$). Relation positive mais avec une dispersion plus importante, suggérant l'influence d'autres facteurs contextuels.

3.3 Comparaison des régions – ANOVA et test de Tukey

Une ANOVA à un facteur a été réalisée pour comparer les scores de bonheur moyens selon la région. Le résultat est hautement significatif ($F \gg 1$, $p < 2.2e-16$), rejetant l'hypothèse nulle d'égalité des moyennes régionales.



Test de Tukey : Western Europe se distingue significativement de toutes les autres régions ($p < 0.001$), avec un écart maximal de +2.52 points vs Sub-Saharan Africa. Sub-Saharan Africa et Africa générale ne diffèrent pas ($p=0.999$). Americas, Europe et Latin America sont statistiquement comparables ($p > 0.99$).

3.4 Test du Chi-deux – Région × Niveau de bonheur

Un test du chi-deux sur la table de contingence Région × HappinessLevel est hautement significatif ($p < 2.2e-16$), confirmant une forte dépendance statistique.





Figure – Distribution des niveaux de bonheur (Low/Medium/High) par région (barres 100% empilées).

4. Analyse Multivariée – Régression Multiple

4.1 Spécification du modèle



4.2 Résultats du modèle final (erreurs robustes HC1)




Figure – Coefficients β avec leur niveau de significativité. Tous $p < 0.05$ après correction HC1.


Le modèle explique **78.8%** de la variance du bonheur. La liberté de choix ($\beta=1.433$) et le soutien social ($\beta=1.183$) ont les effets unitaires les plus forts, devant le PIB ($\beta=0.828$). Tous les prédicteurs sont significatifs après correction HC1.

4.3 Diagnostics du modèle

Test	Statistique	Conclusion
VIF (multicolinéarité)	Max VIF = 4.34 (GDP)	▪ Tous < 5, pas de multicolinéarité sévère
Shapiro-Wilk (résidus)	W=0.990, p=3.17e-05	▪ Légère non-normalité – TCL valide (n=781)
Breusch-Pagan	BP=34.65, p=0.000143	▪ Hétéroscédasticité → SE robustes HC1 appliquées
Cook's distance	44 obs. avec D > 4/n	▪ Pays extrêmes (très pauvres ou très riches)

5. Analyse en Composantes Principales (ACP)

Une ACP a été réalisée sur les 6 variables explicatives standardisées via FactoMineR. Les individus ont été projetés et colorés selon leur région dans le biplot.



Critère de Kaiser : 2 composantes retenues. Dim.1 + Dim.2 expliquent 69.4% de la variance totale — réduction dimensionnelle satisfaisante.

5.2 Coordonnées des variables et cercle des corrélations




Figure 5 – Contributions des variables sur Dim.1 (développement) et Dim.2 (gouvernance & solidarité).

Dim.1 — Indice de développement humain (46%)

GDP (0.850), Health (0.833), Family (0.753) — oppose pays riches/sains aux pays moins développés. Corrélée directement au bonheur.

Dim.2 — Qualité institutionnelle & solidarité (23%)

Generosity (0.789), Corruption (0.584), Freedom (0.404) — discrimine selon la gouvernance et la culture de solidarité.




Figure 5 – Cercle des corrélations (ACP). Les variables GDP, Health et Family pointent fortement vers Dim.1 ; Generosity et Corruption dominant Dim.2.

Dim.1 = « Indice de développement humain » : GDP (0.850), Health (0.833), Family (0.753). Oppose pays riches/sains aux pays moins développés. Corrélée directement au bonheur. Dim.2 = « Qualité institutionnelle et solidarité » : Generosity (0.789), Corruption (0.584), Freedom (0.404). Discrimine selon la gouvernance et la culture de solidarité.

5.3 Biplot – Pays colorés par région




Figure 6 – Biplot ACP avec ellipses de confiance à 90% par région. L'Europe de l'Ouest (haut droit) s'oppose nettement à l'Afrique subsaharienne (bas gauche) sur Dim.1. Les pays nordiques se distinguent aussi sur Dim.2 (générosité/gouvernance).

6. Classification Non Supervisée (K-means)

Un algorithme K-means ($k=3$, $nstart=25$, données centrées-réduites) a été appliqué sur les 6 variables explicatives. Le choix de $k=3$ est cohérent avec la structure visible dans le biplot et reflète une segmentation économique naturelle des pays.

6.1 Profil des clusters



Les trois clusters correspondent à une segmentation claire du développement mondial. Le Cluster 1 (17.4%) rassemble les pays les plus développés : leur GDP moyen (1.34) est presque 3x celui du Cluster 2 (0.45). La générosité est paradoxalement plus élevée dans le Cluster 2 (0.237) que dans le Cluster 3 (0.166) – phénomène documenté : les populations précaires font parfois preuve d'une plus grande solidarité communautaire relative.

6.2 Visualisation K-means




Figure 7 – Clustering K-means (k=3) projeté sur les 2 premières composantes de l'ACP. La séparation est nette entre les clusters 1 et 2 sur Dim.1. Le cluster 3 (intermédiaire) chevauche partiellement les deux autres, reflétant la continuité du développement humain.

7. Conclusion

7.1 Synthèse des résultats

- Le bonheur mondial moyen est de **5.38/10** avec d'importantes inégalités (2.69 à 7.77). Plus de 57% des observations sont en niveau Medium, signe d'un bien-être mondial encore fragile.
- Le **PIB par habitant** est la variable la plus corrélée au bonheur ($r=0.79$), suivi de la santé ($r=0.74$) et du soutien social ($r=0.65$).
- La **régression multiple** ($R^2=0.788$) montre que la liberté de choix ($\beta=1.43$) et le soutien social ($\beta=1.18$) ont les effets unitaires les plus forts. Tous les prédicteurs sont significatifs après correction par erreurs robustes HC1.
- L'**ANOVA** et le test de Tukey révèlent des différences régionales hautement significatives : l'Europe de l'Ouest domine (+2.52 pts vs Afrique subsaharienne).
- L'**ACP** identifie deux dimensions latentes : le développement humain (46%) et la gouvernance/solidarité (23%), structurant l'espace des indicateurs.
- Le **K-means (k=3)** segmente les pays en trois groupes cohérents avec leur niveau de développement, confirmant la structure hiérarchique du bien-être mondial.
- Les **effets temporels** indiquent un pic en 2016 (+0.32 vs 2015) suivi d'un déclin progressif jusqu'en 2019 (-0.28).

7.2 Limites

- Données auto-rapportées (enquête Gallup) – biais culturels de réponse possibles.
- La causalité ne peut pas être établie dans cette analyse.
- Les régions détaillées sont absentes des fichiers 2017–2019 (imputées via countrycode).
- Des modèles à effets fixes pays permettraient de contrôler l'hétérogénéité non observée.

Message clé : Le bonheur n'est pas qu'une question de richesse économique. Si le PIB joue un rôle central, la liberté individuelle, le lien social et la qualité des institutions contribuent de façon indépendante et substantielle au bien-être. Cette analyse multidimensionnelle confirme la vision holistique du World Happiness Report : le développement humain intégral — économique, social, institutionnel — est la clé d'une population heureuse.

Références

Helliwell, J., Layard, R., & Sachs, J. (2019). World Happiness Report 2019. Sustainable Development Solutions Network.

Kaggle Dataset : <https://www.kaggle.com/datasets/unsdsn/world-happiness>

R Core Team (2023). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria.